



# UTILIZAÇÃO DE REDES ADVERSÁRIAS GERADORAS PARA SUPER-RESOLUÇÃO DE IMAGENS CIENTÍFICAS

UM ESTUDO DE CASO

Leonam T. Vasconcelos

Timóteo, 14 de Julho de 2025





# Índice de conteúdo

## 1 Introdução

- Introdução
- Considerações preliminares
- Procedimentos
- Desenvolvimento
- Resultados
- Conclusão
- Referências



# Contexto

## 1 Introdução

- Uma quantidade muito grande de imagens é produzida a todo momento do nosso cotidiano
  - Em média, o ser humano produziu cerca de 1,7 MB de dados por minuto no ano de 2020 [12]
- Esta taxa tende a apenas aumentar [12].



# Motivação e Justificativa

## 1 Introdução

- E se pudéssemos comprimir tais imagens, para reduzir os impactos desta enorme quantidade e depois, houvesse uma forma de recuperar a imagem original a partir da versão comprimida?
- Tal solução ainda poderia ser utilizada para recuperar detalhes de imagens originalmente em baixa resolução, como por exemplo:
  - imagens médicas
  - imagens científicas



# Motivação e Justificativa

## 1 Introdução

- Estes dois grupos de imagens são particularmente interessantes, pois:
  1. Imagens científicas, mais especificamente astronômicas de baixa resolução são facilmente encontradas online
  2. Algumas imagens médicas em particular como Ressonância Magnética não podem, em alguns casos, ser obtidas com uma qualidade maior devido à consequências à saúde do paciente exposto ao equipamento [5]



# Objetivo Geral

## 1 Introdução

Experimentar os trabalhos de Ledig, Moreira e Wang [6, 9, 13] para a elaboração de redes adversárias geradoras treinadas especificamente para a super-resolução de imagens científicas a fim de validarmos os custos e benefícios deste treinamento específico em relação à modelos genericamente treinados.



# Objetivos específicos

## 1 Introdução

1. Definir um sub-conjunto de imagens, especificamente de uma ou duas áreas para especializarmos o trabalho
2. Definir um modelo de redes geradoras adversárias para o contexto apresentado
3. Integrar todo software e dependência necessários para treinar e utilizar o modelo escolhido no objetivo anterior
4. Utilizar as bases de imagens para treinar o modelo escolhido de forma específica
5. Utilizar-se de técnicas de cálculo de similaridade de imagens para avaliar o desempenho do treinamento realizado



# Índice de conteúdo

## 2 Considerações preliminares

- ▶ Introdução
- ▶ Considerações preliminares
- ▶ Procedimentos
- ▶ Desenvolvimento
- ▶ Resultados
- ▶ Conclusão
- ▶ Referências



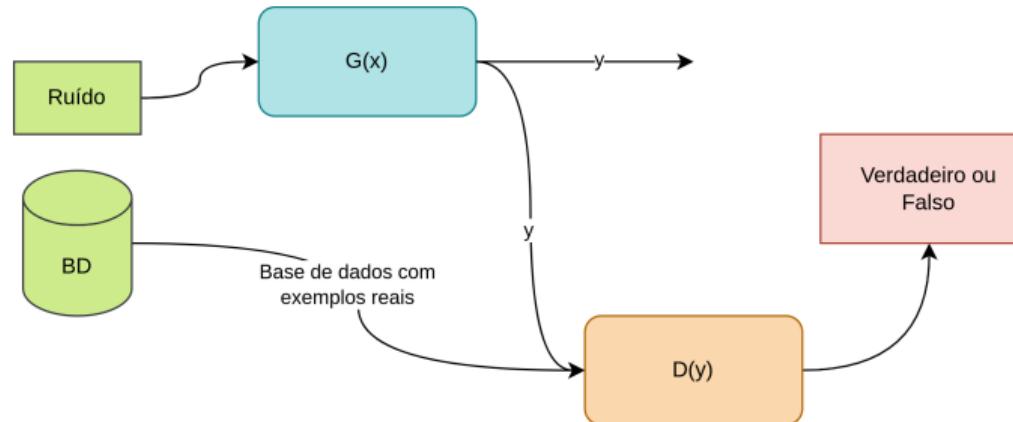
# Sobre os requisitos teóricos

## 2 Considerações preliminares

Este trabalho se baseia fortemente em conceitos de redes neurais em diversas arquiteturas diferentes. Estas, estão mais profundamente detalhadas na monografia, deixando para esta apresentação, a retidão para com o tema.

# Sobre os requisitos teóricos — GAN

## 2 Considerações preliminares

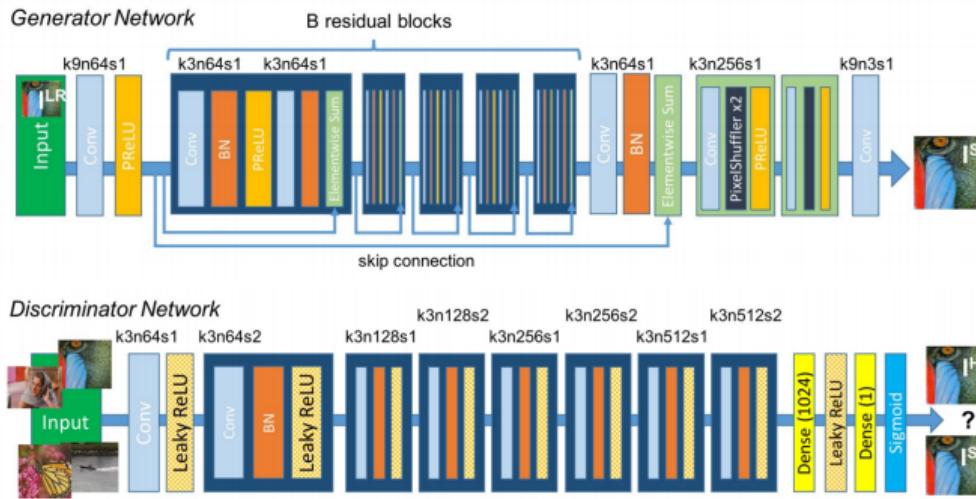


RAG/GAN. Fonte: autor, baseado em [4, 15, 9].



# Sobre os requisitos teóricos — ESRGAN

## 2 Considerações preliminares



SRGAN. Fonte: [6]



# Índice de conteúdo

## 3 Procedimentos

- Introdução
- Considerações preliminares
- Procedimentos
- Desenvolvimento
- Resultados
- Conclusão
- Referências



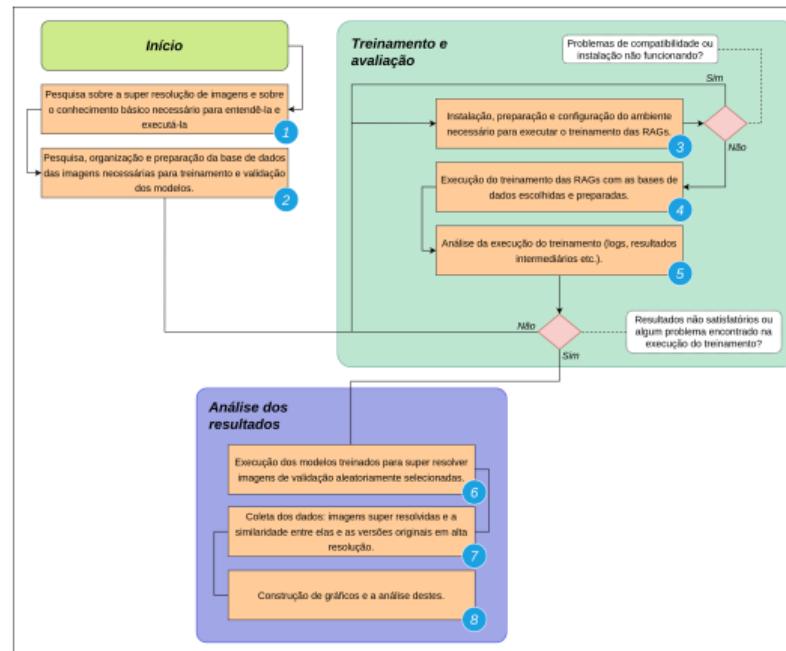
# Considerações sobre o fluxo de trabalho

## 3 Procedimentos

- O desenvolvimento do trabalho foi dividido em 8 fases
- Algumas fases foram executadas uma única vez
- Outras, foram executadas em várias iterações

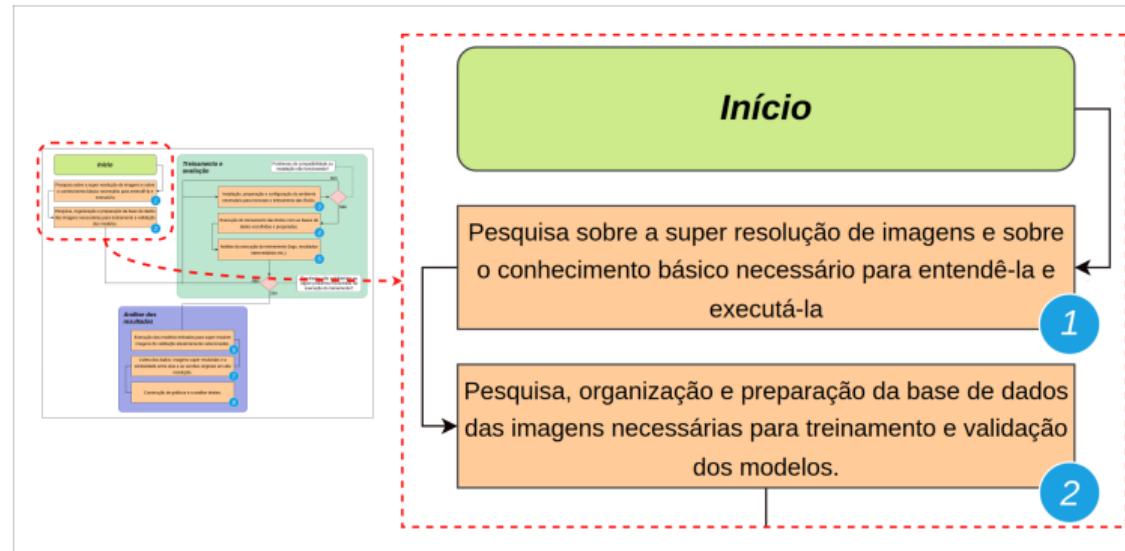
# Detalhamento do fluxo de trabalho

## 3 Procedimentos



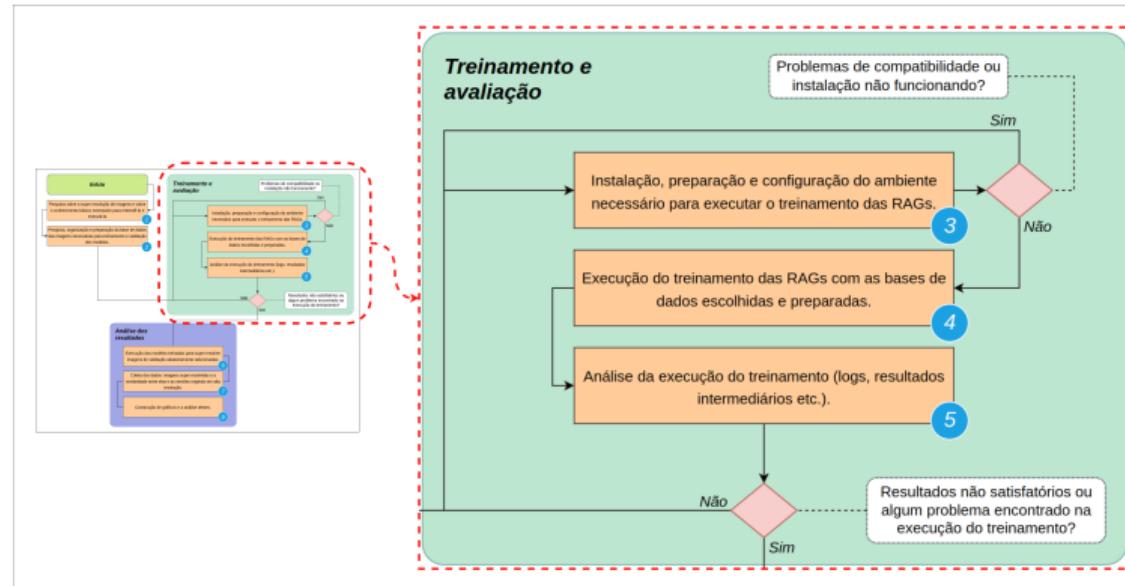
# Detalhamento do fluxo de trabalho

## 3 Procedimentos



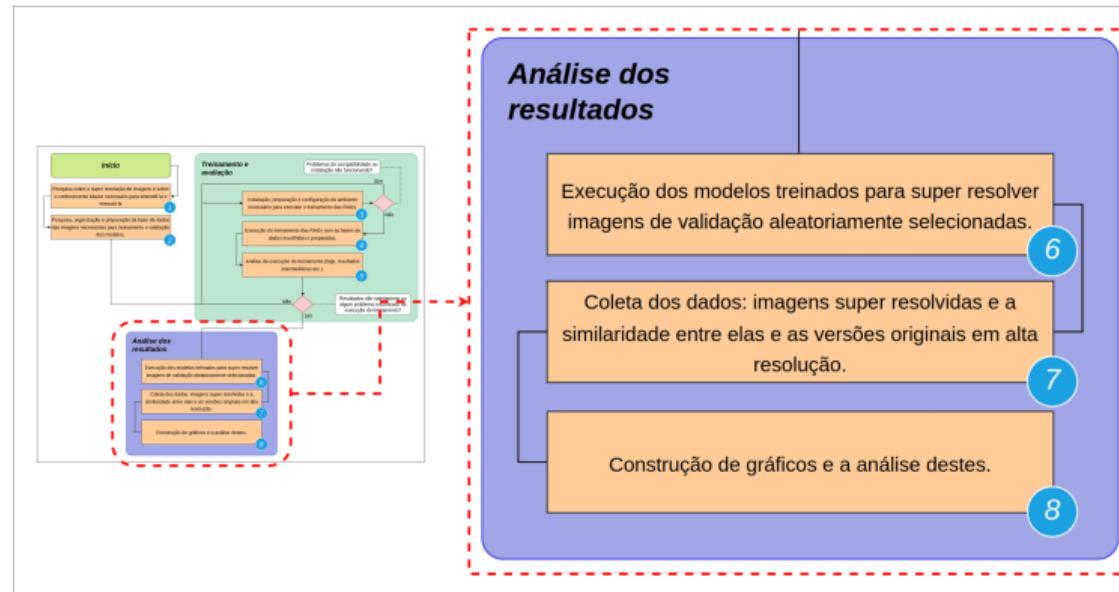
# Detalhamento do fluxo de trabalho

## 3 Procedimentos



# Detalhamento do fluxo de trabalho

## 3 Procedimentos





# Índice de conteúdo

## 4 Desenvolvimento

- ▶ Introdução
- ▶ Considerações preliminares
- ▶ Procedimentos
- ▶ Desenvolvimento
- ▶ Resultados
- ▶ Conclusão
- ▶ Referências



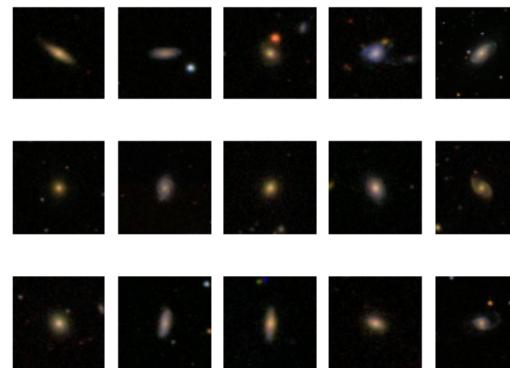
# Captura de imagens para treinamento

4 Desenvolvimento

*Imagens astronômicas*

As imagens astronômicas foram baixadas no site *Kaggle* [11]

Exemplos:



Fonte: Autor, com imagens do *Kaggle* [11].

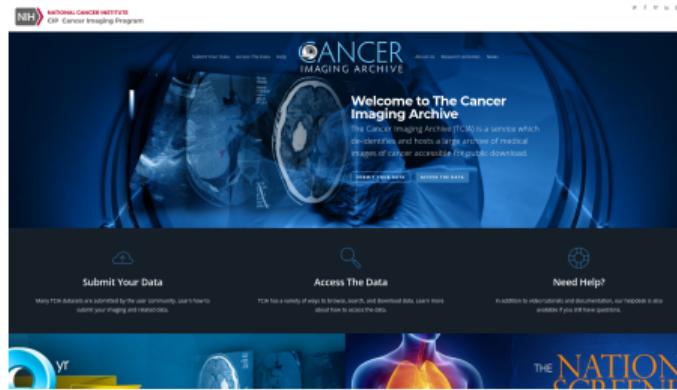


# Captura de imagens para treinamento

## 4 Desenvolvimento

### *Imagens de ressonância magnética*

As imagens de ressonância magnética foram encontradas em um repositório chamado *Cancer Image Archive* [1].



Fonte: *Cancer Image Archive* [1]

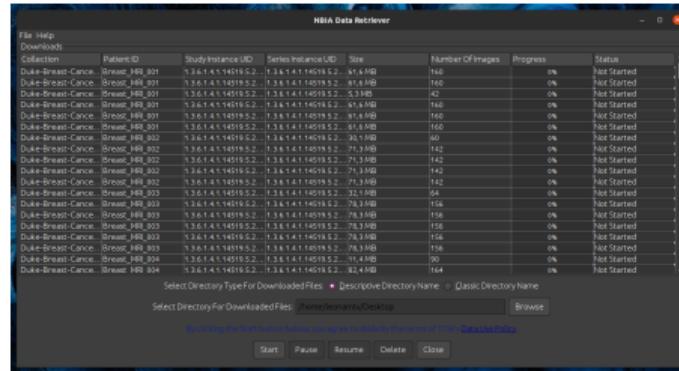


## Captura de imagens para treinamento

## 4 Desenvolvimento

*Imagens de ressonância magnética*

Para fazer o *download*, um instalador chamado *NBIA Data Retriever* [1] deve ser utilizado



Fonte: Captura de tela tirada pelo autor.



# Captura de imagens para treinamento

4 Desenvolvimento

*Imagens de ressonância magnética*

Exemplos:



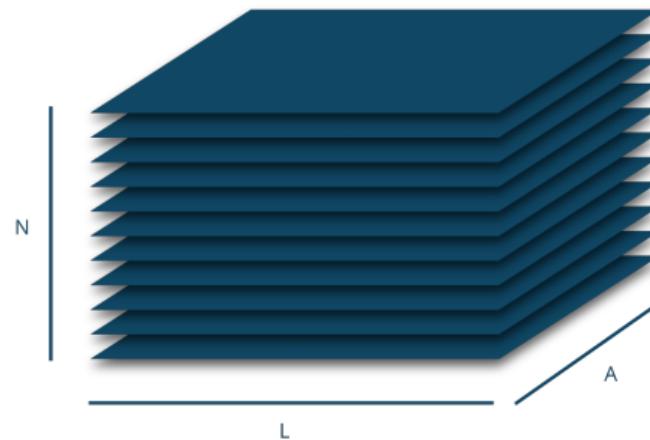
Fonte: Autor, com imagens do *Cancer Imaging Archive* [1].



# Ajustes nas imagens médicas

## 4 Desenvolvimento

As imagens médicas são armazenadas e propagadas em um formato específico: DICOM. [2, 8, 3, 7, 14]



Estrutura de imagens *DICOM*. Fonte: Autor.



# Ajustes nas imagens médicas

## 4 Desenvolvimento

```
(0018, 1511) Positioner Secondary Angle          DS: '2.0'  
(0019, 0010) Private Creator                   LO: 'CARDIO-D.R. 1.0'  
(0019, 1030) [Maximum Frame Size]              UL: 262144  
(0020, 000d) Study Instance UID                UI: 1.3.12.2.1107.5.4.3.123456789012345.19950922.121803.6  
(0020, 000e) Series Instance UID                UI: 1.3.12.2.1107.5.4.3.123456789012345.19950922.121803.8  
(0020, 0010) Study ID                          SH: ''  
(0020, 0011) Series Number                     IS: '1'  
(0020, 0013) Instance Number                  IS: None  
(0020, 0020) Patient Orientation             CS: ''  
(0021, 0010) Private Creator                 LO: 'CARDIO-D.R. 1.0'  
(0021, 1013) [Image Sequence Number]          IS: '15'  
(0028, 0002) Samples per Pixel               US: 1  
(0028, 0004) Photometric Interpretation       CS: 'MONOCHROME2'  
[0028, 0008) Number of Frames                 IS: '96'  
[0028, 0009) Frame Increment Pointer          AI: (0018, 1063)  
(0028, 0010) Rows                            US: 512  
(0028, 0011) Columns                         US: 512  
(0028, 0100) Bits Allocated                 US: 8  
(0028, 0101) Bits Stored                    US: 8  
(0028, 0102) High Bit                      US: 7  
(0028, 0103) Pixel Representation           US: 0  
(0028, 1040) Pixel Intensity Relationship    CS: 'LIN'  
(0028, 1090) Recommended Viewing Mode        CS: 'NAT'  
(0028, 6040) R Wave Pointer                 US: [20, 53, 77]  
(0028, 6100) Mask Subtraction Sequence 1 item(s) ----  
[0028, 6101) Mask Operation                 CS: 'NONE'  
(0028, 6110) Mask Frame Numbers            US: 0
```

Destacando o número de frames – ou número de imagens – nos metadados de um arquivo *DICOM*. Fonte: Autor.



# Ajustes nas imagens médicas

## 4 Desenvolvimento

```
 1 import pydicom
 2 import numpy as np
 3
 4 from PIL import Image
 5
 6 filename='imagem.dcm'
 7
 8 ds = pydicom.dcmread(filename)
 9 image = ds.pixel_array.astype(float)[1]
10
11 scaled_image = (np.maximum(image, 0) / image.max()) * 255.0
12 scaled_image = np.uint8(scaled_image)
13
14 final_image = Image.fromarray(scaled_image)
15
16 final_image.save("imagem.jpg")
```

Código para converter uma imagem *DICOM* para o formato *jpg*. Fonte: Autor.



# Preparação das imagens para treinamento

## 4 Desenvolvimento

Como requisitos obrigatórios para o treinamento, as imagens devem estar em:

- resolução uniforme
- resolução divisível por 4 (específico ao problema atual)
- um formato compatível
- uma estrutura esperada pelo modelo



# Preparação das imagens para treinamento

## 4 Desenvolvimento

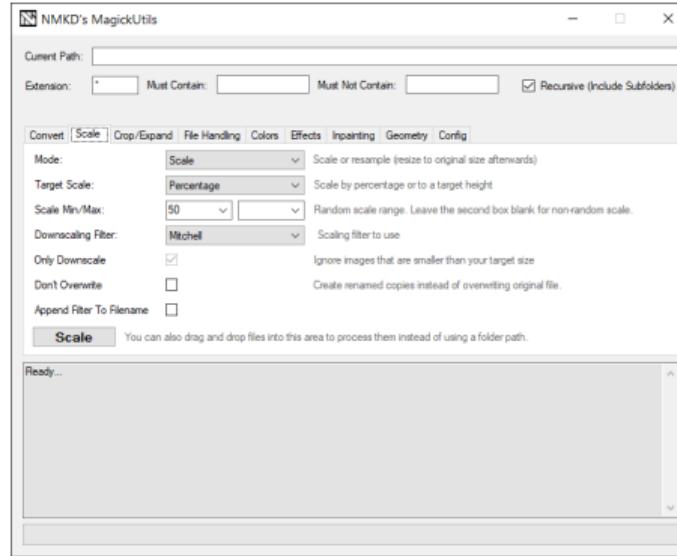
O modelo espera que as imagens estejam distribuídas no formato a seguir:

- Treinamento
  - HR
    - Imagens de treinamento com alta resolução
  - LR
    - Imagens de treinamento com baixa resolução (4x menor que HR)
- Validação
  - HR
    - Imagens de validação com alta resolução
  - LR
    - Imagens de validação com baixa resolução (4x menor que HR)



# Preparação das imagens para treinamento

## 4 Desenvolvimento



Captura de tela do software *Magick-Utils*.  
Fonte: *Github* do criador do software [10].



# Preparação do ambiente para treinamento

## 4 Desenvolvimento

Esta fase inclui:

- Instalação de dependências\*
  - Drivers necessários
  - Versão correta do **python**
  - Dependências do modelo utilizado
- Execução preliminar para checagem de consistência.

# Preparação do ambiente para treinamento

## 4 Desenvolvimento

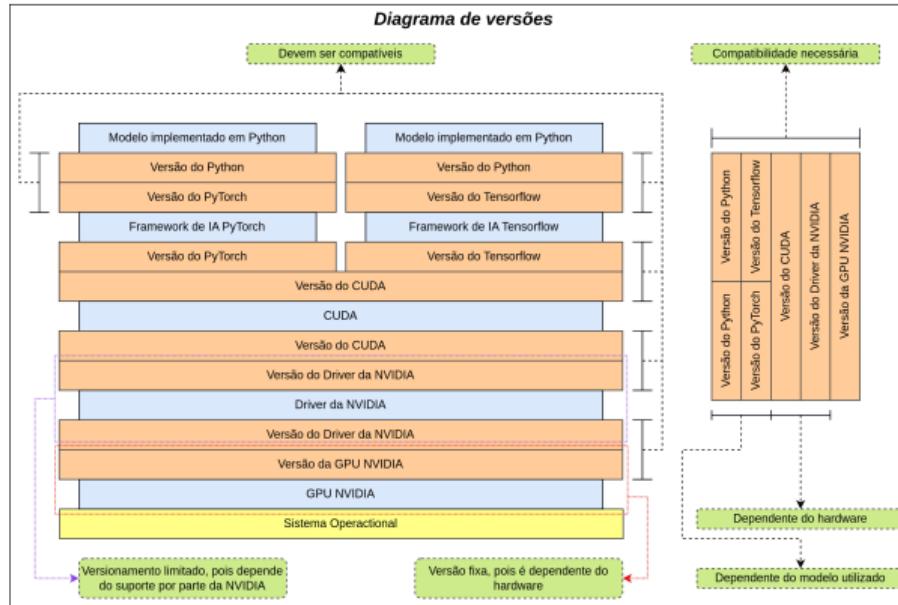


Diagrama de interação entre as partes envolvidas no modelo. Fonte: Autor.



# Treinamento

## 4 Desenvolvimento

Descrição do hardware disponível:

| Item                     | Descrição                             |
|--------------------------|---------------------------------------|
| CPU                      | Intel i7 Octa Core                    |
| Memória RAM              | 16GB                                  |
| Memória de Vídeo         | 2GB                                   |
| Modelo da placa de vídeo | GeForce MX350                         |
| Disco                    | 512GB (apenas 90GB disponível)        |
| Sistema operacional      | Windows 10 e Ubuntu 24.04 disponíveis |



# Treinamento

## 4 Desenvolvimento

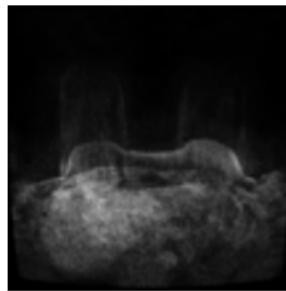
Parâmetros de treinamento:

|                            |      |
|----------------------------|------|
| <i>batch size</i>          | 2    |
| Nº de épocas               | 100  |
| Nº de interações por época | 1000 |



# Coleta de dados

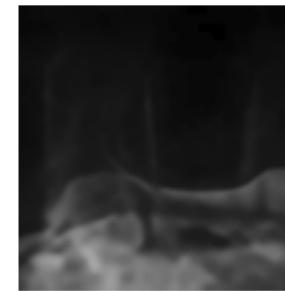
## 4 Desenvolvimento



(a)



(b)



(c)

Amostra aleatoriamente capturada das imagens de ressonância.

Fonte: Autor.

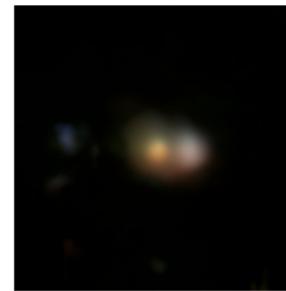


# Coleta de dados

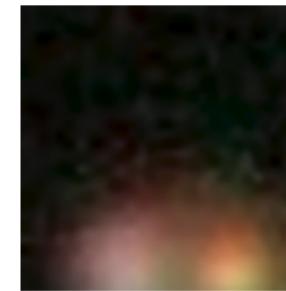
## 4 Desenvolvimento



(a)



(b)



(c)

Amostra aleatoriamente capturada das imagens de astronomia.

Fonte: Autor.



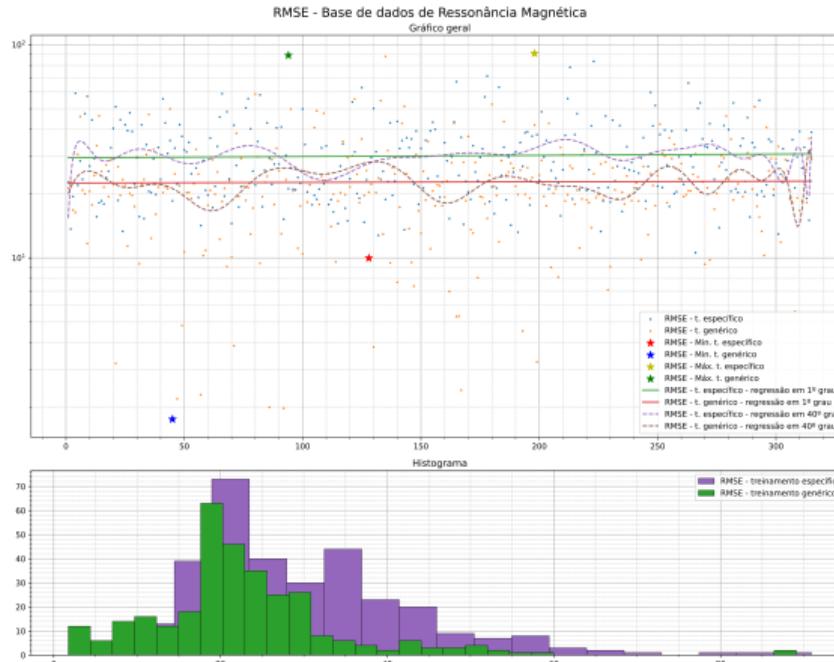
# Índice de conteúdo

## 5 Resultados

- Introdução
- Considerações preliminares
- Procedimentos
- Desenvolvimento
- Resultados
- Conclusão
- Referências

# Resultados: Ressonância Magnética

## 5 Resultados



Cálculo de erro RMSE para base de dados de ressonância magnética. Fonte: Autor.

# Resultados: Ressonância Magnética

## 5 Resultados

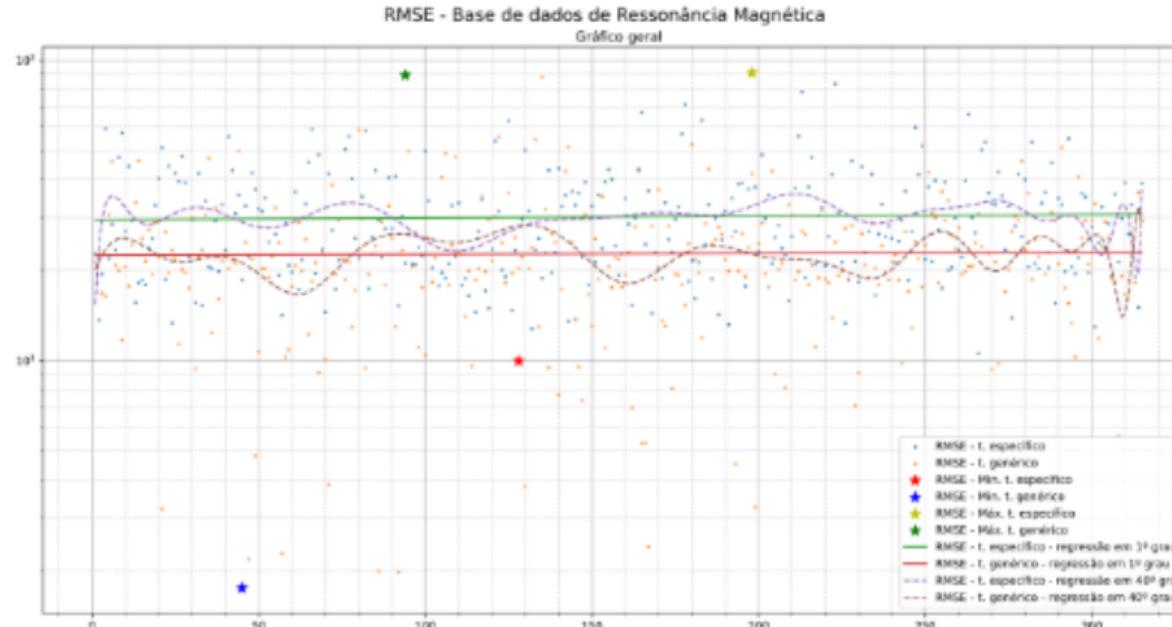
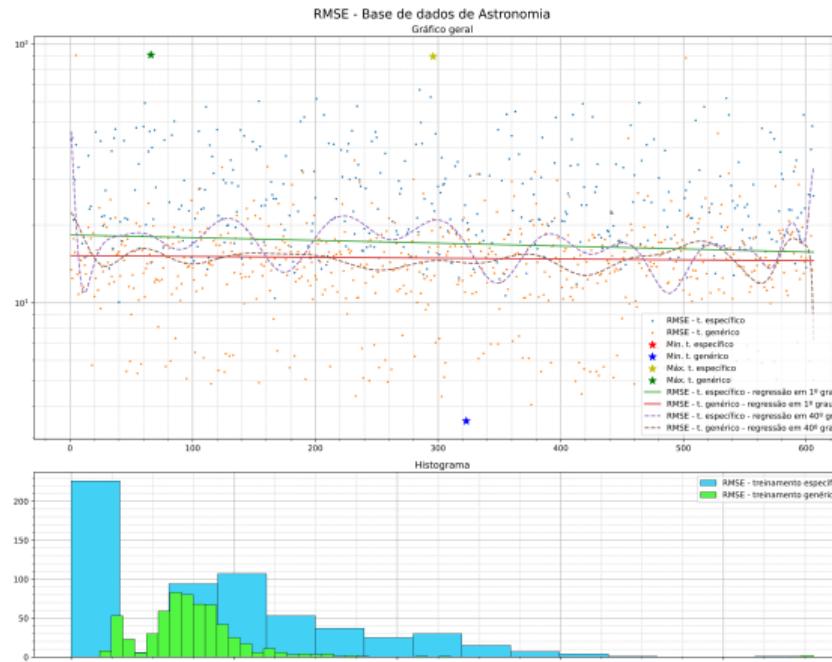


Gráfico de erro RMSE (ressonância) ampliado. Fonte: Autor.

# Resultados: Astronomia

## 5 Resultados



Cálculo de erro RMSE para base de dados astronômica. Fonte: Autor.

# Resultados: Astronomia

## 5 Resultados

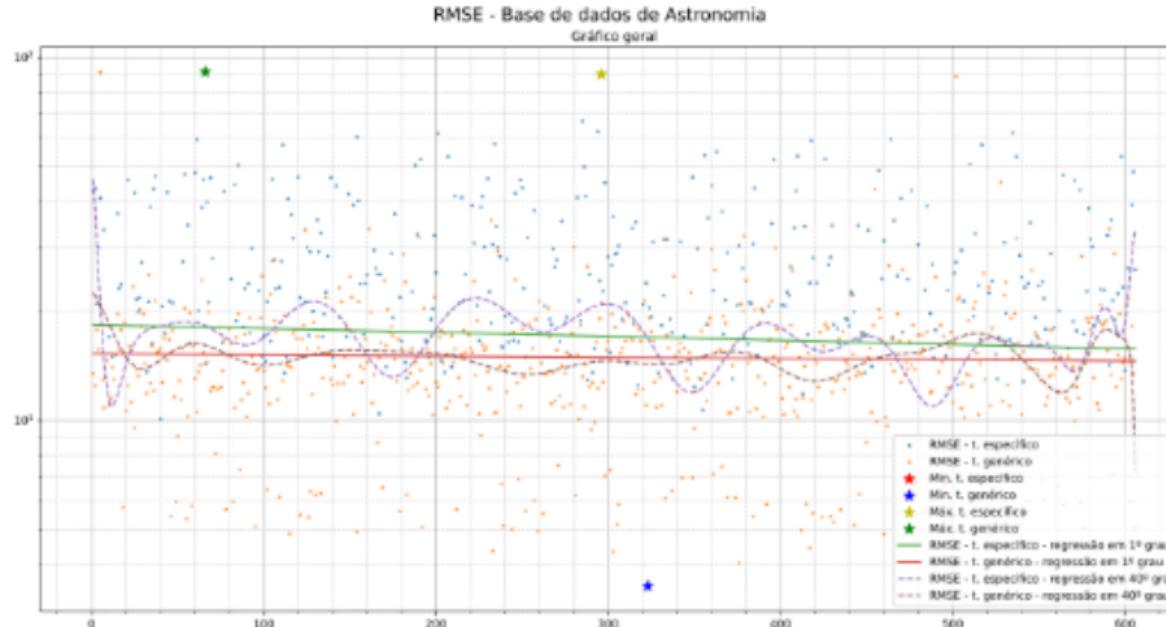


Gráfico de erro RMSE (astronomia) ampliado. Fonte: Autor.



# Índice de conteúdo

## 6 Conclusão

- ▶ Introdução
- ▶ Considerações preliminares
- ▶ Procedimentos
- ▶ Desenvolvimento
- ▶ Resultados
- ▶ Conclusão
- ▶ Referências



# Conclusão

## 6 Conclusão

O treinamento **genérico** produziu consistentemente, melhores resultados que os treinamentos **específicos**.



# Conclusão

## 6 Conclusão

O treinamento **genérico** produziu consistentemente, melhores resultados que os treinamentos **específicos**.

Possíveis motivos:

- Limitações de recursos: memória e processador



# Conclusão

## 6 Conclusão

O treinamento **genérico** produziu consistentemente, melhores resultados que os treinamentos **específicos**.

Possíveis motivos:

- Limitações de recursos: memória e processador
- Limitação de tempo



# Índice de conteúdo

## 7 Referências

- Introdução
- Considerações preliminares
- Procedimentos
- Desenvolvimento
- Resultados
- Conclusão
- Referências



-  **Cancer Imaging Archive.**  
Cancer Imaging Archive, June 2022.
-  **DICOM Standard.**  
History, 2019.
-  **DICOM Standard.**  
Current Edition, 2024.
-  **A. Gulli, A. Kapoor, and S. Pal.**  
Deep Learning with TensorFlow 2 and Keras - Google Books, Dec. 2019.



-  R. Gupta, A. Sharma, and A. Kumar.  
Super-Resolution using GANs for Medical Imaging.  
*Procedia Computer Science*, 173:28–35, Jan. 2020.
-  C. Ledig, L. Theis, F. Huszar, J. Caballero, A. Cunningham, A. Acosta, A. Aitken, A. Tejani, J. Totz, Z. Wang, and W. Shi.  
Photo-Realistic Single Image Super-Resolution Using a Generative Adversarial Network.  
*arXiv:1609.04802 [cs, stat]*, May 2017.  
arXiv: 1609.04802.



-  **Medical Connections.**  
DICOM DateTime Format, Jan. 2007.  
Section: kb.
-  **Medical Connections.**  
DicomObjects | DICOM API / SDK Toolkit, Aug. 2011.
-  **F. Moreira.**  
GERAÇÃO DE IMAGENS EM SUPER RESOLUÇÃO COM REDES GERADORAS ADVERSÁRIAS, July 2019.
-  **N00MKRAD.**  
MagickUtils, June 2022.  
original-date: 2020-07-20T15:21:16Z.



-  A. Srivastava.  
Astronomy Image Classification Dataset, July 2024.
-  Vish.  
How Much Data Is Created Every Day in 2021? [You'll be shocked!], June 2020.
-  X. Wang, K. Yu, S. Wu, J. Gu, Y. Liu, C. Dong, C. C. Loy, Y. Qiao, and X. Tang.  
ESRGAN: Enhanced Super-Resolution Generative Adversarial Networks.  
*arXiv:1809.00219 [cs]*, Sept. 2018.  
arXiv: 1809.00219.



 A. Weston.

Understanding DICOM, Oct. 2020.

 A. Zhang, Z. C. Lipton, M. Li, and A. J. Smola.

Dive into Deep Learning.

*arXiv:2106.11342 [cs]*, July 2021.

arXiv: 2106.11342.